MySkill

FINAL PROJECT

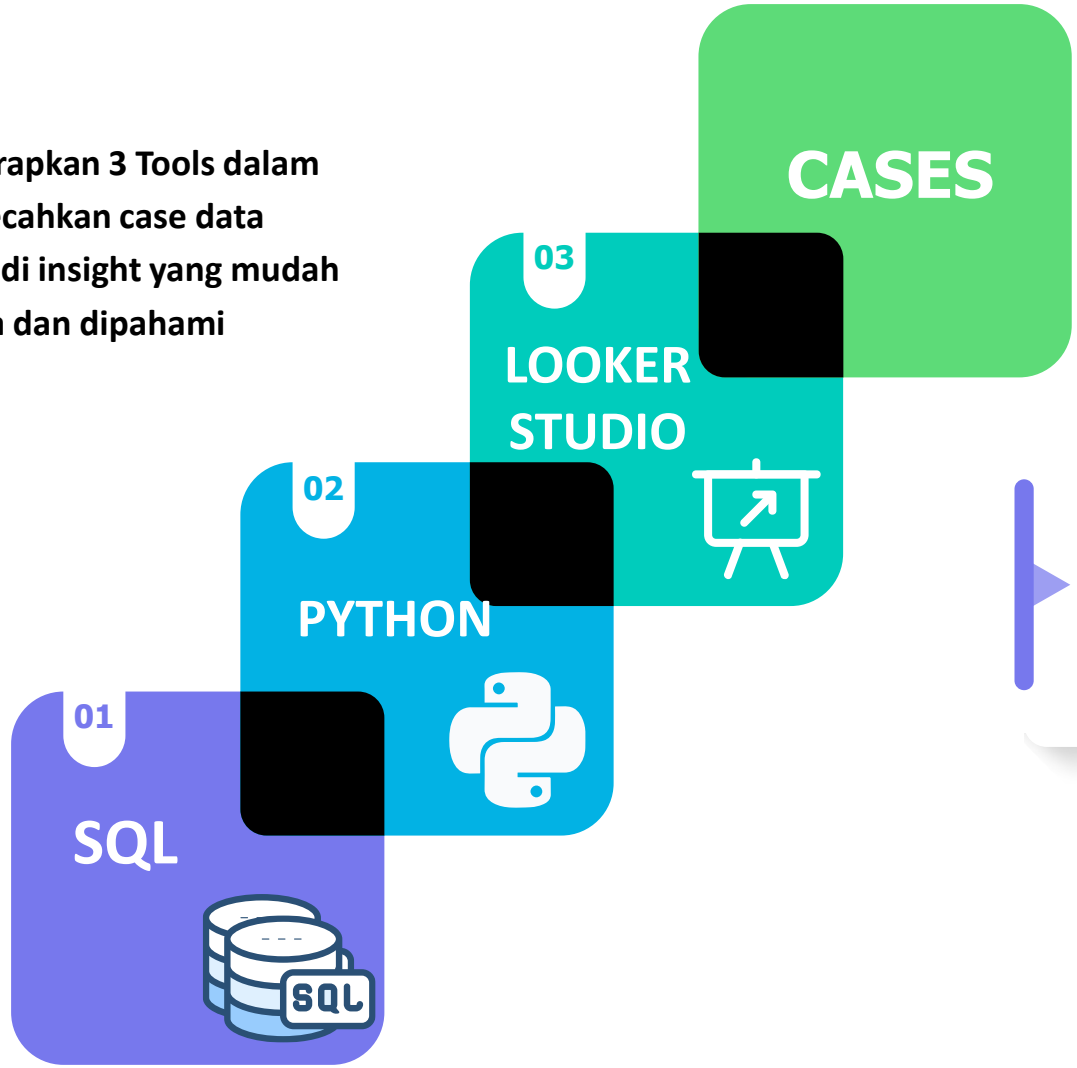
Data Analysis

FADHLUL IKRAM

#RintisKarirImpian



Menerapkan 3 Tools dalam memecahkan case data menjadi insight yang mudah dibaca dan dipahami



SQL

Membuat Query dalam menampilkan data tabel yang dibutuhkan pada soal di BigQuery

PYTHON

Menggunakan Bahasa Pandas dalam mencari jawaban dari soal pada Google Collab

Looker Studio

Membuat Visualisasi dari data yang telah diberikan menjadi dashboard interaktif pada Google Looker Studio

DATA SET



- order_detail
- sku_detail
- customer_detail
- payment_detail

```python
df_od['order_date'] = pd.to_datetime(df_od['order_date'])
df_od['tahun'] = df_od['order_date'].dt.year


merged = df_od.merge(df_sd, left_on='sku_id', right_on='id', suffixes=('_order', '_sku'))


valid = merged[merged['is_valid


qty_2021 = valid[valid['tahun']                                    y_ordered'].sum().reset_index().re
qty_2022 = valid[valid['tahun']                                    y_ordered'].sum().reset_index().re


cat_compare = qty_2021.merge(qt                                    ').fillna(0)
cat_compare['qty_2021'] = cat_c
cat_compare['qty_2022'] = cat_c
cat_compare['selisih'] = cat_co                                    qty_2021']
cat_compare = cat_compare.sort_v                                   op=True)

cat_compare
```

Python

02

PYTHON

DATASET OVERVIEW

variable	class	description
order_detail:		
id	object	angka unik dari order / id_order
customer_id	object	angka unik dari pelanggan
order_date	object	tanggal saat dilakukan transaksi
sku_id	object	angka unik dari produk (sku adalah stock keeping unit)
price	int64	harga yang tertera pada tagging harga
qty_ordered	int64	jumlah barang yang dibeli oleh pelanggan
before_discount	float64	nilai harga total dari produk (price * qty_ordered)
discount_amount	float64	nilai diskon product total
after_discount	float64	nilai harga total produk ketika sudah dikurangi dengan diskon
is_gross	int64	menunjukkan pelanggan belum membayar pesanan
is_valid	int64	menunjukkan pelanggan sudah melakukan pembayaran
is_net	int64	menunjukkan transaksi sudah selesai
payment_id	int64	angka unik dari metode pembayaran

SKU DETAIL

sku_detail:		
id	object	angka unik dari produk (dapat digunakan untuk key saat join)
sku_name	object	nama dari produk
base_price	float64	harga barang yang tertera pada tagging harga / price
cogs	int64	cost of goods sold / total biaya untuk menjual 1 produk
category	object	kategori produk

CUSTOMER DETAIL

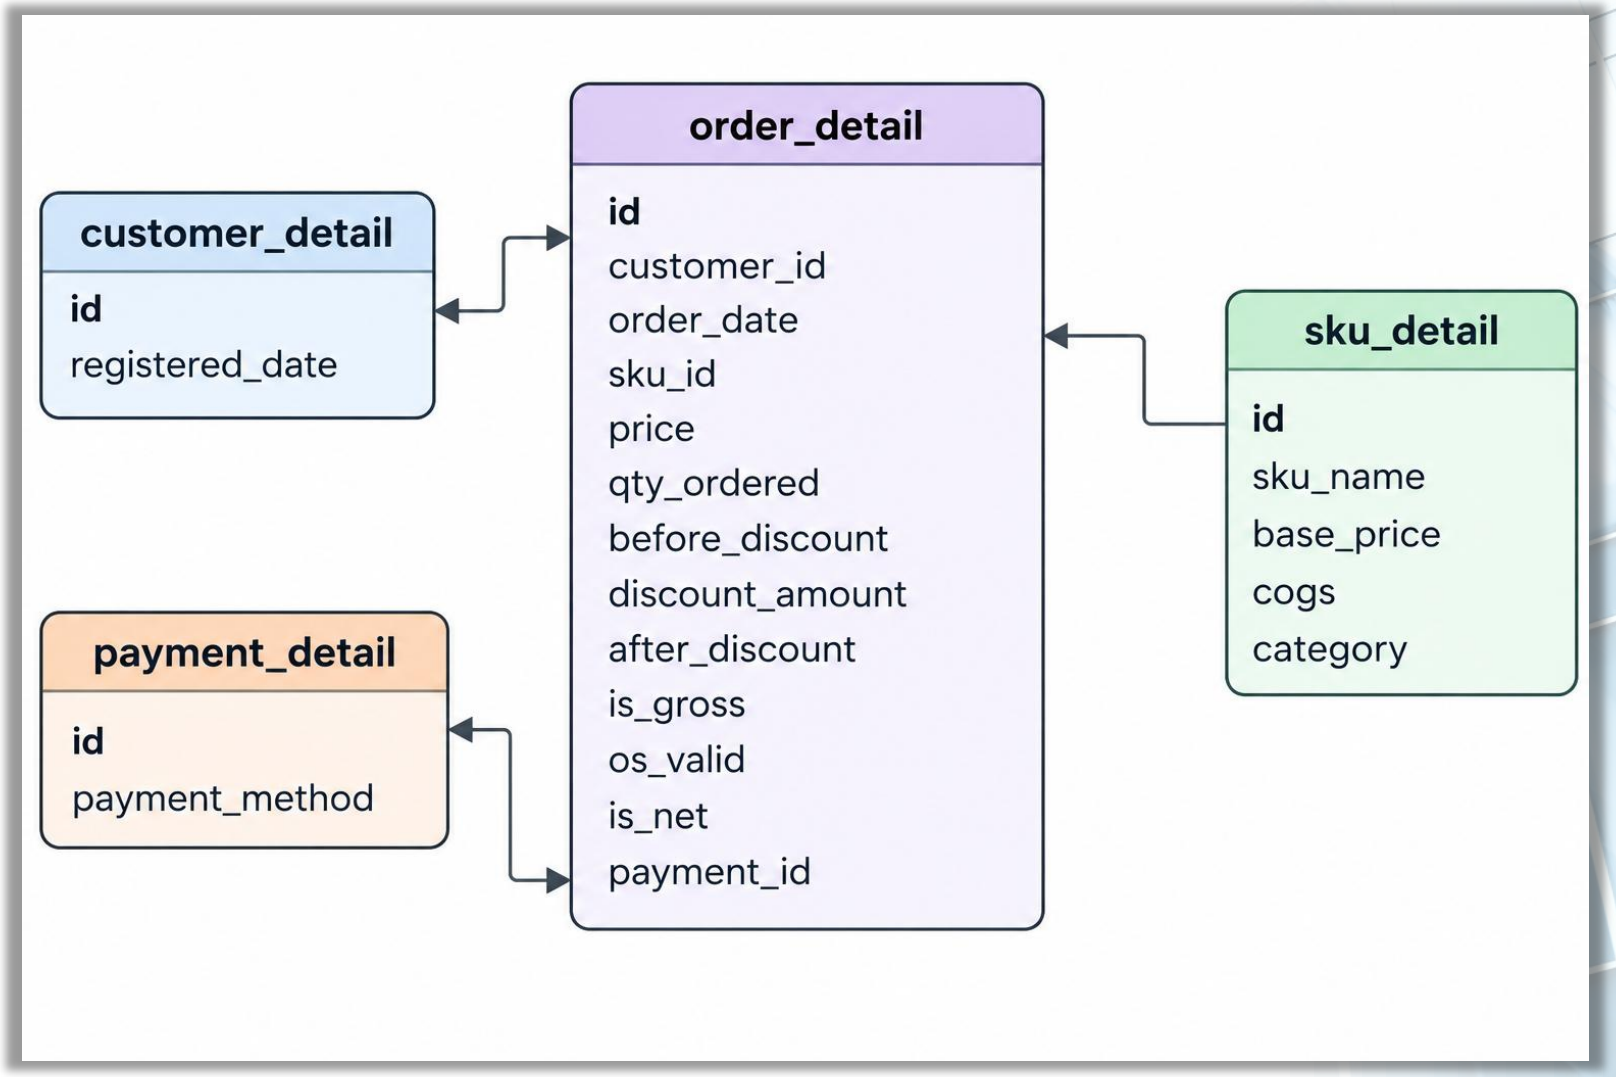
customer_detail:		
id	object	angka unik dari pelanggan
registered_date	object	tanggal pelanggan mulai mendaftarkan diri sebagai anggota

PAYMENT DETAIL

payment_detail:		
id	int64	angka unik dari metode pembayaran
payment_method	object	metode pembayaran yang digunakan



TABLE SCHEME



```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pandas.tseries.offsets import BDay
```

- **pandas as pd**→ olah data tabel (DataFrame)
- **numpy as np** → operasi angka dan array
- **matplotlib.pyplot as plt** → buat grafik dasar
- **seaborn as sns** → grafik lebih rapi dan statistik
- **pandas.tseries.offsets import Bday** → hitung tanggal hari kerja (tanpa weekend)

```python
#Sumber data yang digunakan
path_od = "https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/order_detail.csv"
path_pd = "https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/payment_detail.csv"
path_cd = "https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/customer_detail.csv"
path_sd = "https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/sku_detail.csv"
df_od = pd.read_csv(path_od)
df_pd = pd.read_csv(path_pd)
df_cd = pd.read_csv(path_cd)
df_sd = pd.read_csv(path_sd)
```

- **path_...** → variabel untuk menyimpan lokasi file (file path)
- **df_...** → variabel untuk menyimpan DataFrame (data tabel di pandas)

- **import pandas as pd** — mengimpor library pandas (untuk mengolah data tabel/dataframe) dan memberinya alias pd.
- **Empat variabel path_...** — menyimpan URL file CSV mentah (raw) dari GitHub, masing-masing untuk data:
- **pd.read_csv**(...) — membaca masing-masing file CSV langsung dari URL tersebut (tanpa perlu download manual) dan mengubahnya menjadi DataFrame (tabel data di pandas):
- **df_od** → dataframe order_detail
- **df_pd** → dataframe payment_detail
- **df_cd** → dataframe customer_detail
- **df_sd** → dataframe sku_detail

```
df_od.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5884 entries, 0 to 5883
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   id               5884 non-null   object
 1   customer_id      5884 non-null   object
 2   order_date       5884 non-null   object
 3   sku_id           5884 non-null   object
 4   price            5884 non-null   int64
 5   qty_ordered      5884 non-null   int64
 6   before_discount  5884 non-null   float64
 7   discount_amount  5884 non-null   float64
 8   after_discount   5884 non-null   float64
 9   is_gross         5884 non-null   int64
 10  is_valid         5884 non-null   int64
 11  is_net           5884 non-null   int64
 12  payment_id       5884 non-null   int64
dtypes: float64(3), int64(6), object(4)
memory usage: 597.7+ KB
```

```
df_od ['order_date'] =
pd.to_datetime(df_od['order_date'])
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5884 entries, 0 to 5883
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   id               5884 non-null   object
 1   customer_id      5884 non-null   object
 2   order_date       5884 non-null   datetime64[ns]
 3   sku_id           5884 non-null   object
 4   price            5884 non-null   int64
 5   qty_ordered      5884 non-null   int64
 6   before_discount  5884 non-null   float64
 7   discount_amount  5884 non-null   float64
 8   after_discount   5884 non-null   float64
 9   is_gross         5884 non-null   int64
 10  is_valid         5884 non-null   int64
 11  is_net           5884 non-null   int64
 12  payment_id       5884 non-null   int64
dtypes: datetime64[ns](1), float64(3), int64(6), object(3)
memory usage: 597.7+ KB
```

- to_datetime () → mengubah data menjadi format tanggal/waktu

Column order_date dan registration_date yang sebelum nya berupa object di ubah menjadi date time

Case

01 Tentukan **TOP 5 Produk kategori Mobiles & Tablets** dengan kuantitas penjualan tertinggi (**valid = 1**) selama tahun **2022** sebagai perkiraan hadiah Festival Akhir Tahun.

Dear Data Analyst,

Akhir tahun ini, perusahaan akan memberikan hadiah bagi pelanggan yang memenangkan kompetisi **Festival Akhir Tahun**. Tim Marketing membutuhkan bantuan untuk menentukan perkiraan hadiah yang akan diberikan pada pemenang kompetisi nantinya. Hadiah tersebut akan diambil dari **TOP 5 Produk** dari Kategori **Mobiles & Tablets** selama tahun 2022, dengan jumlah kuantitas penjualan (valid = 1) paling tinggi. Mohon bantuan, untuk mengirimkan data tersebut sebelum akhir bulan ini ke Tim Marketing. Atas bantuan yang diberikan, kami mengucapkan terima kasih.

Regards
Tim Marketing

01 Tentukan **TOP 5 Produk kategori Mobiles & Tablets** dengan kuantitas penjualan tertinggi (**valid = 1**) selama tahun **2022** sebagai perkiraan hadiah Festival Akhir Tahun.

```
df_od_sd=pd.merge(
    df_od,
    df_sd,
    left_on='sku_id',
    right_on='id',
    suffixes=('', '_sku'))
df_od_sd.head(5)
```

```
filtered = df_od_sd[
    (df_od_sd['category'] == 'Mobiles & Tablets') &
    (df_od_sd['order_date'].dt.year == 2022) &
    (df_od_sd['is_valid'] == 1)
]
filtered
```

```
top5 = (
    filtered.groupby(['sku_id', 'sku_name'])['qty_ordered']
    .sum()
    .reset_index()
    .sort_values('qty_ordered', ascending=False)
    .head(5)
    .reset_index(drop=True)
)

top5
```

- **pd.merge(** → menggabungkan 2 DataFrame, seperti JOIN di SQL.
- **df_od,** → DataFrame pertama, yaitu data order_detail.
- **df_sd,** → DataFrame kedua, yaitu data sku_detail.
- **left_on='sku_id',** → kolom yang dijadikan kunci dari df_od.
- **right_on='id',** → kolom yang dijadikan kunci dari df_sd.
- **suffixes=('', '_sku')** → kalau ada nama kolom yang sama, kolom dari df_sd diberi akhiran _sku.
- **df_od_sd.head(5)** → melihat 5 baris pertama hasil merge.

- **df_od_sd[** → memilih baris berdasarkan kondisi.
- **category == 'Mobiles & Tablets'** → hanya mengambil kategori **Mobiles & Tablets**.
- **&** → artinya **DAN**. Semua kondisi harus terpenuhi.
- **order_date.dt.year == 2022** → hanya mengambil transaksi pada tahun **2022**.
- **is_valid == 1** → hanya mengambil transaksi yang **valid**.

- **top5 = (** → membuat variabel bernama top5.
- **filtered.groupby(['sku_id', 'sku_name'])** → mengelompokkan data berdasarkan **SKU ID dan nama produk**.
- **['qty_ordered']** → yang dihitung adalah kolom jumlah barang yang dipesan.
- **.sum()** → menjumlahkan total qty_ordered untuk setiap produk.
- **.reset_index()** → mengubah hasil groupby kembali menjadi DataFrame biasa.
- **.sort_values('qty_ordered', ascending=False)** → mengurutkan berdasarkan jumlah terjual dari **terbesar → terkecil**.
- **.head(5)** → mengambil **5 baris teratas**.
- **.reset_index(drop=True)** → merapikan nomor index menjadi 0, 1, 2, 3, 4.

01 Tentukan **TOP 5 Produk kategori Mobiles & Tablets** dengan kuantitas penjualan tertinggi (**valid = 1**) selama tahun **2022** sebagai perkiraan hadiah Festival Akhir Tahun.

INSIGHT

	sku_id	sku_name	qty_ordered
0	P313303	IDROID_BALRX7-Gold	1000
1	P754831	IDROID_BALRX7-Jet black	31
2	P774890	Infinix Hot 4-Gold	15
3	P661542	samsung_Grand Prime Plus-Black	11
4	P592314	samsung_Grand Prime Plus-Silver	10

- **Dominasi Mutlak Satu Produk:** IDROID_BALRX7-Gold menjadi pemenang mutlak dengan penjualan 1000 unit, jauh melampaui posisi kedua (31 unit). Ini menandakan adanya "Hero Product" yang sangat diminati pasar.
- **Kesenjangan Volume yang Ekstrem:** Terjadi penurunan drastis antara peringkat 1 dan 2 (dari 1000 ke 31 unit), menunjukkan minat pelanggan kategori Mobiles & Tablets tahun 2022 sangat terpusat pada satu model saja.
- **Warna "Gold" Jadi Favorit:** Varian warna "Gold" muncul dua kali di Top 3 (IDROID dan Infinix), mengindikasikan warna emas masih jadi daya tarik utama pembeli gadget di periode tersebut.
- **Persaingan Brand di Top 5:** Meski IDROID mendominasi posisi puncak, brand lain seperti Infinix dan Samsung tetap punya tempat di daftar Top 5, meski dengan volume yang jauh lebih kecil.

01 Tentukan **TOP 5 Produk kategori Mobiles & Tablets** dengan kuantitas penjualan tertinggi (**valid = 1**) selama tahun **2022** sebagai perkiraan hadiah Festival Akhir Tahun.

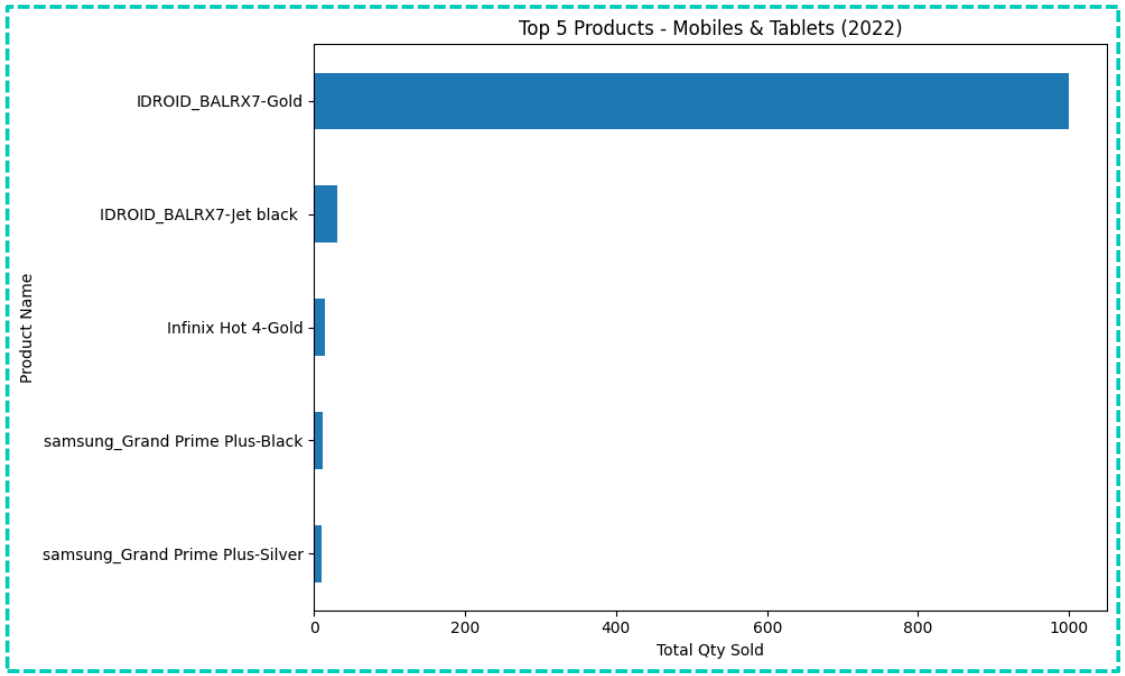
```
import matplotlib.pyplot as plt


top5.plot(
    x='sku_name',
    y='qty_ordered',
    kind='barh',
    xlabel='Total Qty Sold',
    ylabel='Product Name',
    figsize=(10,6),
    title='Top 5 Products - Mobiles & Tablets (2022)',
    legend=False
)
plt.tight_layout()
plt.show()
```

- **import matplotlib.pyplot as plt** — mengimpor library matplotlib untuk membuat visualisasi.
- **top5.plot(...)** — memanggil fungsi plot bawaan pandas langsung dari DataFrame top5.
- **x='sku_name'** — kolom sku_name dijadikan label sumbu Y (nama produk).
- **y='qty_ordered'** — kolom qty_ordered dijadikan nilai yang ditampilkan pada sumbu X.
- **kind='barh'** — jenis chart yang dibuat adalah horizontal bar chart.
- **xlabel='Total Qty Sold'** — memberi label pada sumbu X.
- **ylabel='Product Name'** — memberi label pada sumbu Y.
- **figsize=(10,6)** — mengatur ukuran chart (lebar 10, tinggi 6).
- **title='...'** — memberi judul pada chart.
- **legend=False** — menyembunyikan legend karena hanya ada satu seri data.
- **plt.tight_layout()** — merapikan layout agar label/elemen tidak terpotong.
- **plt.show()** — menampilkan chart yang sudah dibuat.

01 Tentukan **TOP 5 Produk kategori Mobiles & Tablets** dengan kuantitas penjualan tertinggi (**valid = 1**) selama tahun **2022** sebagai perkiraan hadiah Festival Akhir Tahun.

REKOMENDASI



- **Jadikan IDROID_BALRX7-Gold sebagai fokus stok & marketing utama** — karena penjualannya jauh melampaui produk lain, pastikan ketersediaan stok tetap terjaga (hindari stockout) dan pertimbangkan promosi bundling untuk memaksimalkan momentum.
- **Investigasi penyebab gap ekstrem** antara produk #1 dan #2 (1000 vs 31 unit) — apakah karena harga sangat kompetitif, campaign khusus, atau memang superior dari sisi fitur — supaya insight-nya bisa direplikasi ke produk lain.
- **Eksplorasi varian warna "Gold"** lebih lanjut di kategori Mobiles & Tablets, karena warna ini muncul dua kali di Top 3 — bisa jadi sinyal preferensi pasar yang layak dijadikan pertimbangan saat stocking produk baru.
- **Jangan abaikan diversifikasi brand** — meski IDROID mendominasi, tetap pertahankan stok Infinix dan Samsung di Top 5 supaya nggak terlalu bergantung pada satu produk/brand saja.

Case

02.1 Mohon dilakukan pengecekan kuantitas penjualan 15 kategori pada 2021 dan 2022 untuk melihat dugaan penurunan penjualan di 2022.

Dear Data Analyst,

Menindaklanjuti meeting gabungan Tim Werehouse dan Tim Marketing, kami menemukan bahwa ketersediaan stock produk dengan Kategori Others pada akhir 2022 kemarin masih banyak.
1.Kami mohon bantuan untuk melakukan pengecekan data penjualan kategori tersebut dengan tahun 2021 secara kuantitas penjualan. Dugaan sementara kami, telah terjadi penurunan kuantitas penjualan pada 2022 dibandingkan 2021. (Mohon juga menampilkan data ke-15 kategori)

2. Apabila memang terjadi penurunan kuantitas penjualan pada kategori Others, kami mohon bantuan untuk menyediakan data TOP 20 nama produk yang mengalami penurunan paling tinggi pada 2022 jika dibanding dengan 2021. Hal ini kami gunakan sebagai bahan diskusi pada meeting selanjutnya.
Mohon bantuan untuk mengirimkan data tersebut paling lambat 4 hari dari hari ini. Atas bantuan yang diberikan, kami mengucapkan terima kasih.

Regards
Tim Werehouse

02.1 Mohon dilakukan pengecekan kuantitas penjualan 15 kategori pada 2021 dan 2022 untuk melihat dugaan penurunan penjualan di 2022.

```python
import pandas as pd

# 1. Load data
df_od = pd.read_csv('https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/order_detail.csv')
df_sd= pd.read_csv('https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/sku_detail.csv')
```

```python
df_od['order_date'] = pd.to_datetime(df_od['order_date'])
df_od['tahun'] = df_od['order_date'].dt.year


merged = df_od.merge(df_sd, left_on='sku_id', right_on='id', suffixes=('_order', '_sku'))


valid = merged[merged['is_valid'] == 1]


qty_2021 = valid[valid['tahun'] == 2021].groupby('category')['qty_ordered'].sum().reset_index().rename(columns={'qty_ordered': 'qty_2021'})
qty_2022 = valid[valid['tahun'] == 2022].groupby('category')['qty_ordered'].sum().reset_index().rename(columns={'qty_ordered': 'qty_2022'})


cat_compare = qty_2021.merge(qty_2022, on='category', how='outer').fillna(0)
cat_compare['qty_2021'] = cat_compare['qty_2021'].astype(int)
cat_compare['qty_2022'] = cat_compare['qty_2022'].astype(int)
cat_compare['selisih'] = cat_compare['qty_2022'] - cat_compare['qty_2021']
cat_compare = cat_compare.sort_values('selisih').reset_index(drop=True)

cat_compare
```

- **import pandas as pd** — mengimpor library pandas untuk mengolah data.
- **df_od = pd.read_csv(...)** — membaca file CSV order_detail dari GitHub, disimpan ke variabel df_od.
- **df_sd = pd.read_csv(...)** — membaca file CSV sku_detail dari GitHub, disimpan ke variabel df_sd.

- **pd.to_datetime(...)** — mengubah kolom order_date jadi tipe datetime.
- **dt.year** — mengambil tahun dari order_date, disimpan sebagai kolom tahun.
- **merge(...)** — menggabungkan df_od dengan df_sd berdasarkan sku_id = id, jadi merged.
- **valid = merged[is_valid == 1]** — filter hanya transaksi yang valid.
- **qty_2021 / qty_2022** — hitung total qty_ordered per category, masing-masing untuk tahun 2021 dan 2022.
- **cat_compare = qty_2021.merge(qty_2022, ..., how='outer').fillna(0)** — gabungkan qty 2021 & 2022 per kategori, isi 0 kalau kategori tidak ada datanya di salah satu tahun.
- **astype(int)** — pastikan kolom qty jadi tipe integer.
- **selisih = qty_2022 - qty_2021** — hitung selisih penjualan antar tahun.
- **sort_values('selisih')** — urutkan kategori dari selisih terkecil (penurunan terbesar) ke terbesar (kenaikan terbesar).
- **cat_compare** — tampilkan hasil akhir tabel perbandingan.

02.1 Mohon dilakukan pengecekan kuantitas penjualan 15 kategori pada 2021 dan 2022 untuk melihat dugaan penurunan penjualan di 2022.

INSIGHT

	category	qty_2021	qty_2022	selisih
0	Others	426	263	-163
1	Soghaat	759	612	-147
2	Men Fashion	237	175	-62
3	Beauty & Grooming	168	153	-15
4	Books	171	195	24
5	Appliances	124	148	24
6	Health & Sports	173	200	27
7	Computing	109	153	44
8	School & Education	184	237	53
9	Home & Living	193	250	57
10	Kids & Baby	170	227	57
11	Entertainment	77	150	73
12	Superstore	327	536	209
13	Women Fashion	140	489	349
14	Mobiles & Tablets	107	1154	1047

- **Mobiles & Tablets tumbuh paling eksplosif**, melonjak dari 107 unit (2021) menjadi 1.154 unit (2022) — selisih +1.047, jauh melampaui kategori lain. Ini kemungkinan besar didorong oleh satu produk dominan (IDROID_BALRX7-Gold) yang laris manis di 2022.
- **Women Fashion** juga mencatat kenaikan signifikan (+349), dari 140 ke 489 unit, menandakan tren positif di kategori fashion wanita.
- **Others dan Soghaat justru mengalami penurunan paling tajam** (-163 dan -147), mengindikasikan pergeseran minat pelanggan menjauh dari kategori ini.
- **Sebagian besar kategori lain** (Books, Appliances, Health & Sports, Computing, dll) menunjukkan pertumbuhan moderat dan stabil, tidak ada penurunan drastis selain tiga kategori teratas (Others, Soghaat, Men Fashion).

02.1 Mohon dilakukan pengecekan kuantitas penjualan 15 kategori pada 2021 dan 2022 untuk melihat dugaan penurunan penjualan di 2022.

```python
import matplotlib.pyplot as plt

colors = ['#EA4335' if v < 0 else '#34A853' for v in cat_compare['selisih']]

fig, ax = plt.subplots(figsize=(10, 8))
bars = ax.barh(cat_compare['category'], cat_compare['selisih'], color=colors)

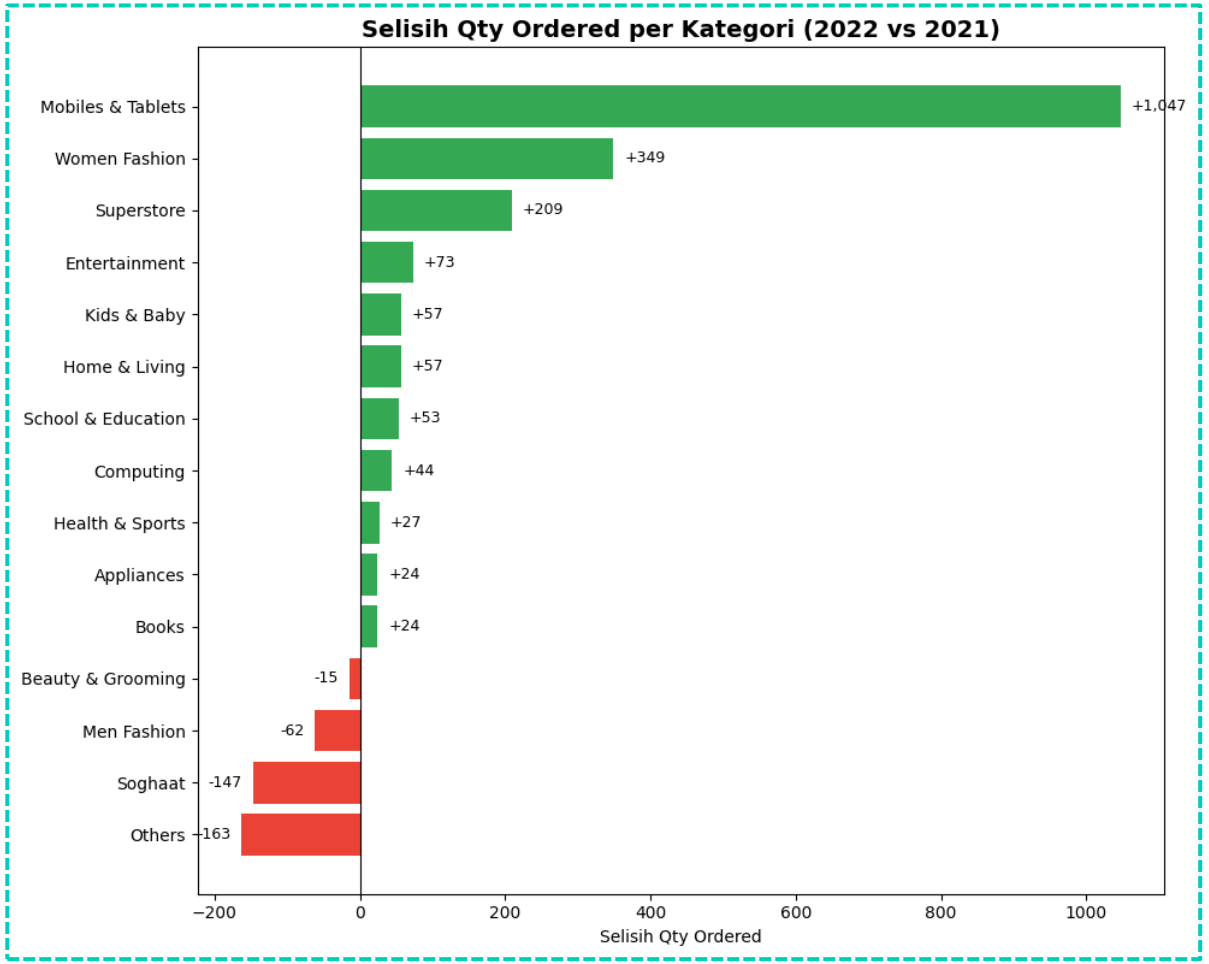
for bar, v in zip(bars, cat_compare['selisih']):
    x = bar.get_width()
    align = 'left' if v >= 0 else 'right'
    offset = 15 if v >= 0 else -15
    ax.text(x + offset, bar.get_y() + bar.get_height()/2, f'{v:+,}', va='center', ha=align, fontsize=9)

ax.axvline(0, color='black', linewidth=0.8)
ax.set_title('Selisih Qty Ordered per Kategori (2022 vs 2021)', fontsize=14, fontweight='bold')
ax.set_xlabel('Selisih Qty Ordered')
plt.tight_layout()
plt.savefig('selisih_category_2021_2022.png', dpi=150)
plt.show()
```

- **colors = [...]** — bikin list warna: merah kalau selisih negatif, hijau kalau positif.
- **fig, ax = plt.subplots(figsize=(10, 8))** — bikin canvas/figure dengan ukuran 10x8.
- **bars = ax.barh(...)** — bikin horizontal bar chart dari category (sumbu Y) dan selisih (sumbu X), diwarnai sesuai colors.
- **for bar, v in zip(bars, cat_compare['selisih']):** — loop tiap bar untuk kasih label angka di ujungnya.
- **x = bar.get_width()** — ambil panjang/lebar bar (nilai selisihnya).
- **align = 'left' if v >= 0 else 'right'** — kalau nilai positif, teks rata kiri; kalau negatif, rata kanan (biar nggak numpuk sama bar).
- **offset = 15 if v >= 0 else -15** — geser posisi teks sedikit (kanan untuk positif, kiri untuk negatif) biar tidak nempel ke bar.
- **ax.text(...)** — tampilkan label angka selisih (dengan format +/-) di samping tiap bar.
- **ax.axvline(0, ...)** — bikin garis vertikal tegas di titik 0, sebagai pemisah antara nilai negatif dan positif.
- **ax.set_title(...)** — kasih judul chart.
- **ax.set_xlabel(...)** — kasih label sumbu X.
- **plt.tight_layout()** — rapikan layout supaya tidak ada elemen yang terpotong.
- **plt.savefig(...)** — simpan chart sebagai file PNG.
- **plt.show()** — tampilkan chart-nya.

02.1 Mohon dilakukan pengecekan kuantitas penjualan 15 kategori pada 2021 dan 2022 untuk melihat dugaan penurunan penjualan di 2022.

REKOMENDASI



- **Genjot stok & campaign Mobiles & Tablets**, karena kategori ini melonjak paling ekstrem (+1.047) — manfaatkan momentum untuk perluas varian produk serupa.
- **Perkuat lini Women Fashion** yang juga tumbuh signifikan (+349), berpotensi jadi kategori andalan berikutnya.
- **Evaluasi ulang strategi kategori Others dan Soghaat**, karena keduanya mengalami penurunan paling tajam (-163 dan -147) — cari tahu penyebabnya, apakah karena pergeseran tren, kurangnya promosi, atau masalah ketersediaan produk.
- **Pertahankan kategori dengan pertumbuhan moderat** (Books, Appliances, Health & Sports, dll) dengan strategi restock yang stabil, tanpa perlu perubahan besar.

02.2

Jika terjadi penurunan pada kategori Others, mohon data TOP 20 produk dengan penurunan kuantitas terbesar pada 2022 dibanding 2021 sebagai bahan diskusi meeting.

```python
import pandas as pd

# 1. Load data
df_sd= pd.read_csv('https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/sku_detail.csv')
```

```python
df_od['order_date'] = pd.to_datetime(df_od['order_date'])
df_od['tahun'] = df_od['order_date'].dt.year


merged = df_od.merge(df_sd, left_on='sku_id', right_on='id', suffixes=('_order', '_sku'))


valid = merged[merged['is_valid'] == 1]


qty_2021 = valid[valid['tahun'] == 2021].groupby('category')['qty_ordered'].sum().reset_index().rename(columns={'qty_ordered': 'qty_2021'})
qty_2022 = valid[valid['tahun'] == 2022].groupby('category')['qty_ordered'].sum().reset_index().rename(columns={'qty_ordered': 'qty_2022'})


cat_compare = qty_2021.merge(qty_2022, on='category', how='outer').fillna(0)
cat_compare['qty_2021'] = cat_compare['qty_2021'].astype(int)
cat_compare['qty_2022'] = cat_compare['qty_2022'].astype(int)
cat_compare['selisih'] = cat_compare['qty_2022'] - cat_compare['qty_2021']
cat_compare = cat_compare.sort_values('selisih').reset_index(drop=True)

cat_compare
```

- **import pandas as pd** — mengimpor library pandas.
- **df_sd = pd.read_csv(...)** — membaca file CSV sku_detail dari GitHub, disimpan ke df_sd.

- **others = valid[valid['category'] == 'Others']** — filter data valid, hanya ambil kategori "Others".
- **qty_2021 = ...** — hitung total qty_ordered per sku_name khusus tahun 2021, kolom hasilnya diganti nama jadi qty_2021.
- **qty_2022 = ...** — sama seperti di atas, tapi untuk tahun 2022, kolomnya jadi qty_2022.
- **compare = qty_2021.merge(qty_2022, on=['sku_name'], how='outer').fillna(0)** — gabungkan data 2021 & 2022 per produk, isi 0 kalau produk tidak muncul di salah satu tahun.
- **compare['qty_2021'] = astype(int)** — pastikan kolom qty 2021 jadi tipe integer.
- **compare['qty_2022'] = astype(int)** — pastikan kolom qty 2022 jadi tipe integer.
- **compare['selisih'] = qty_2022 - qty_2021** — hitung selisih penjualan tiap produk antar tahun.
- **top20_turun = compare.sort_values('selisih').head(20).reset_index(drop=True)** — urutkan dari selisih terkecil (penurunan terbesar), ambil 20 produk teratas.
- **top20_turun** — tampilkan hasilnya, yaitu 20 produk kategori "Others" dengan penurunan penjualan terbesar dari 2021 ke 2022.

02.2

Jika terjadi penurunan pada kategori Others, mohon data TOP 20 produk dengan penurunan kuantitas terbesar pada 2022 dibanding 2021 sebagai bahan diskusi meeting.

INSIGHT

	sku_name	qty_2021	qty_2022	selisih
0	RB_Dettol Germ Busting Kit-bf	200	45	-155
1	Dawlance_MD 10 + DWB 600	23	0	-23
2	Telemall_MM-DR-HB-L	23	2	-21
3	iu_Tickets General Enclosure-Islamabad	20	0	-20
4	RS_Rehmat-e-Shereen Mix Mithai	13	0	-13
5	kansai_NeverWet	10	1	-9
6	sindbad_Sindbad Gift Card-3	7	0	-7
7	emart_00-1	7	1	-6
8	Vouch 365 2016	5	0	-5
9	Am-PTV_ATS-004-M	5	0	-5
10	duma_4561253300294	4	0	-4
11	sockoye_QG in Quarter Grey	4	0	-4
12	The Vitamin Company Kojic Acid Whitening Cream...	4	0	-4
13	aw_Octane Booster-12oz./354ml	3	0	-3
14	Trans2_LW 999	3	0	-3
15	MEGUIAR_G12711	4	1	-3
16	aw_Super Concentrated Fuel Injector (Black)-5....	2	0	-2
17	sstop_Universallensclipkit	2	0	-2
18	Transcend_64GB JetFlash 810	2	0	-2
19	JBS_IFAM-009	2	0	-2

- **RB_Dettol Germ Busting Kit-bf** mengalami penurunan paling ekstrem, dari 200 unit (2021) menjadi hanya 45 unit (2022) — selisih -155, jauh melampaui produk lain di daftar ini.
- **Mayoritas produk (15 dari 20) benar-benar hilang dari penjualan di 2022** (qty_2022 = 0), termasuk produk yang cukup laris di 2021 seperti Dawlance_MD 10+DWB 600 (-23) dan Telemall_MM-DR-HB-L (-21). Ini mengindikasikan produk tersebut kemungkinan sudah discontinued, out of stock permanen, atau kehilangan demand total.
- **Penurunan didominasi produk dengan volume kecil** (qty_2021 di bawah 25 unit untuk sebagian besar item), berbeda dengan Dettol yang jadi outlier karena volumenya jauh lebih besar sebelum anjlok.

02.2

Jika terjadi penurunan pada kategori Others, mohon data TOP 20 produk dengan penurunan kuantitas terbesar pada 2022 dibanding 2021 sebagai bahan diskusi meeting.

```python
import matplotlib.pyplot as plt

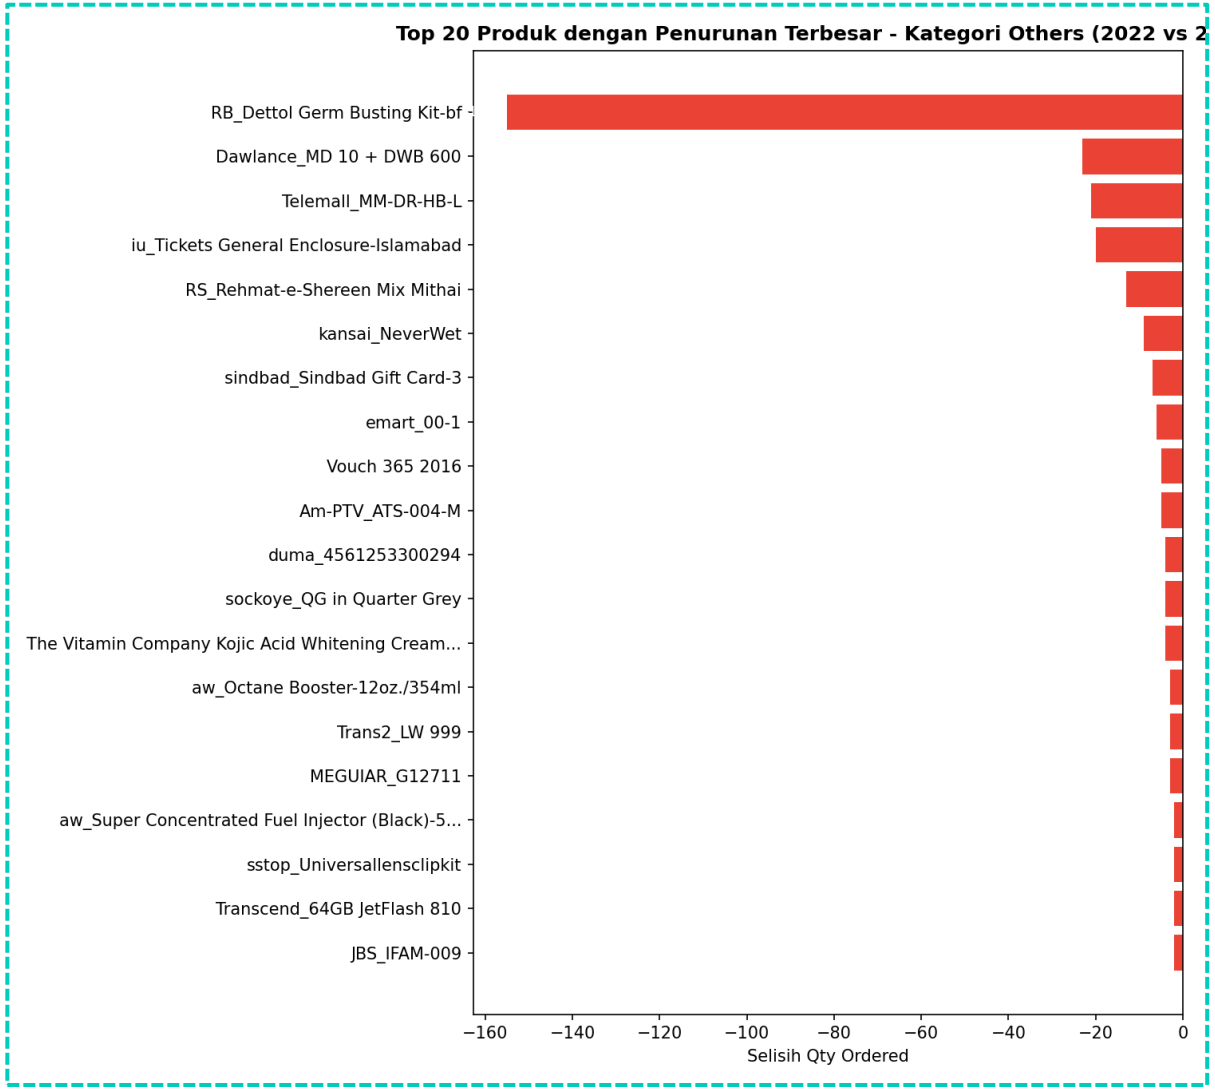
fig, ax = plt.subplots(figsize=(10, 9))
bars = ax.barh(top20_turun['sku_name'], top20_turun['selisih'], color='#EA4335')

for bar, v in zip(bars, top20_turun['selisih']):
    ax.text(bar.get_width() - 3, bar.get_y() + bar.get_height()/2, f'{v}',
            va='center', ha='right', fontsize=8, color='white')

ax.set_title('Top 20 Produk dengan Penurunan Terbesar - Kategori Others (2022 vs 2021)',
             fontsize=12, fontweight='bold')
ax.set_xlabel('Selisih Qty Ordered')
plt.tight_layout()
plt.savefig('top20_turun_others.png', dpi=150)
plt.show()
```

- **fig, ax = plt.subplots(figsize=(10, 9))** — bikin canvas/figure ukuran 10x9.
- **bars = ax.barh(...)** — bikin horizontal bar chart, sumbu Y sku_name, sumbu X selisih, warna merah.
- **for bar, v in zip(bars, top20_turun['selisih']):** — loop tiap bar untuk kasih label angka.
- **ax.text(...)** — tampilkan nilai selisih di dalam ujung bar (rata kanan, warna putih).
- **ax.set_title(...)** — kasih judul chart.
- **ax.set_xlabel(...)** — kasih label sumbu X.
- **plt.tight_layout()** — rapikan layout supaya tidak ada yang terpotong.
- **plt.savefig(...)** — simpan chart jadi file PNG.
- **plt.show()** — tampilkan chart-nya.

02.2 Jika terjadi penurunan pada kategori Others, mohon data TOP 20 produk dengan penurunan kuantitas terbesar pada 2022 dibanding 2021 sebagai bahan diskusi meeting.



REKOMENDASI

- **Investigasi khusus RB_Dettol Germ Busting Kit-bf** — cari tahu penyebab penurunan drastisnya (stockout, perubahan supplier, atau pergeseran demand karena pandemi mereda), karena ini satu-satunya produk dengan dampak signifikan di kategori Others.
- **Evaluasi status ketersediaan produk yang qty_2022-nya = 0** — pastikan apakah memang sengaja di-discontinue atau justru hilang karena masalah supply chain yang perlu diperbaiki.
- **Fokuskan analisis lanjutan pada kategori Others secara keseluruhan** (bukan cuma top 20 ini), karena kategori ini tercatat mengalami penurunan terbesar kedua secara agregat (-163) di antara semua kategori — kemungkinan besar produk-produk kecil seperti ini yang berkontribusi.

Case

03 Untuk promo ulang tahun perusahaan, mohon data Customer ID dan Registered Date pelanggan dengan is_gross = 1 selama 2022.

Dear Data Analyst,

Terkait ulang tahun perusahaan pada 2 bulan mendatang, Tim Digital Marketing akan memberikan informasi promo bagi pelanggan pada akhir bulan ini. Kriteria pelanggan yang akan kami butuhkan adalah mereka yang sudah melakukan check-out namun belum melakukan pembayaran (is_gross = 1) selama tahun 2022. Data yang kami butuhkan adalah ID Customer dan Registered Date.
Mohon bantuan, untuk mengirimkan data tersebut sebelum akhir bulan ini ke Tim Digital Marketing. Atas bantuan yang diberikan, kami mengucapkan terima kasih.

Regards
Tim Digital Marketing

03

Untuk promo ulang tahun perusahaan, mohon data Customer ID dan Registered Date pelanggan dengan is_gross = 1 selama 2022.

```python
import pandas as pd

df_od = pd.read_csv('https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/order_detail.csv')
df_sd= pd.read_csv('https://raw.githubusercontent.com/dataskillsboost/FinalProjectDA11/main/sku_detail.csv')
```

```python
df_od_sd=pd.merge(
    df_od,
    df_cd,
    left_on='customer_id',
    right_on='id')
df_od_sd.head(5)

df_od_sd[
    (df_od_sd['is_gross'] == 1) &
    (df_od_sd['is_valid'] == 0) &
    (df_od_sd['is_net'] == 0) &
    (df_od_sd['order_date'].dt.year == 2022)
][['customer_id', 'registered_date']].drop_duplicates().sort_values('registered_date', ascending=False).reset_index(drop=True)
```

- **import pandas as pd** — mengimpor library pandas.
- **df_od = pd.read_csv(...)** — membaca file order_detail dari GitHub, disimpan ke df_od.
- **df_sd = pd.read_csv(...)** — membaca file sku_detail dari GitHub, disimpan ke df_sd.

- **df_od_sd = pd.merge(df_od, df_cd, left_on='customer_id', right_on='id')** — gabungkan df_od dengan df_cd (data customer), berdasarkan customer_id = id.
- **df_od_sd.head(5)** — tampilkan 5 baris pertama hasil merge untuk cek.
- **df_od_sd[...]** — filter data dengan beberapa kondisi:
- **(is_gross == 1)** — hanya transaksi yang tercatat sebagai gross.
- **(is_valid == 0)** — transaksi yang **tidak valid**.
- **(is_net == 0)** — transaksi yang bukan net.
- **(order_date.dt.year == 2022)** — hanya transaksi tahun 2022.
- **[['customer_id', 'registered_date']]** — ambil hanya dua kolom: customer_id dan registered_date.
- **.drop_duplicates()** — hapus baris duplikat.
- **.sort_values('registered_date', ascending=False)** — urutkan dari tanggal registrasi terbaru ke terlama.
- **.reset_index(drop=True)** — reset ulang index tabel.

03 Untuk promo ulang tahun perusahaan, mohon data Customer ID dan Registered Date pelanggan dengan is_gross = 1 selama 2022.

INSIGHT

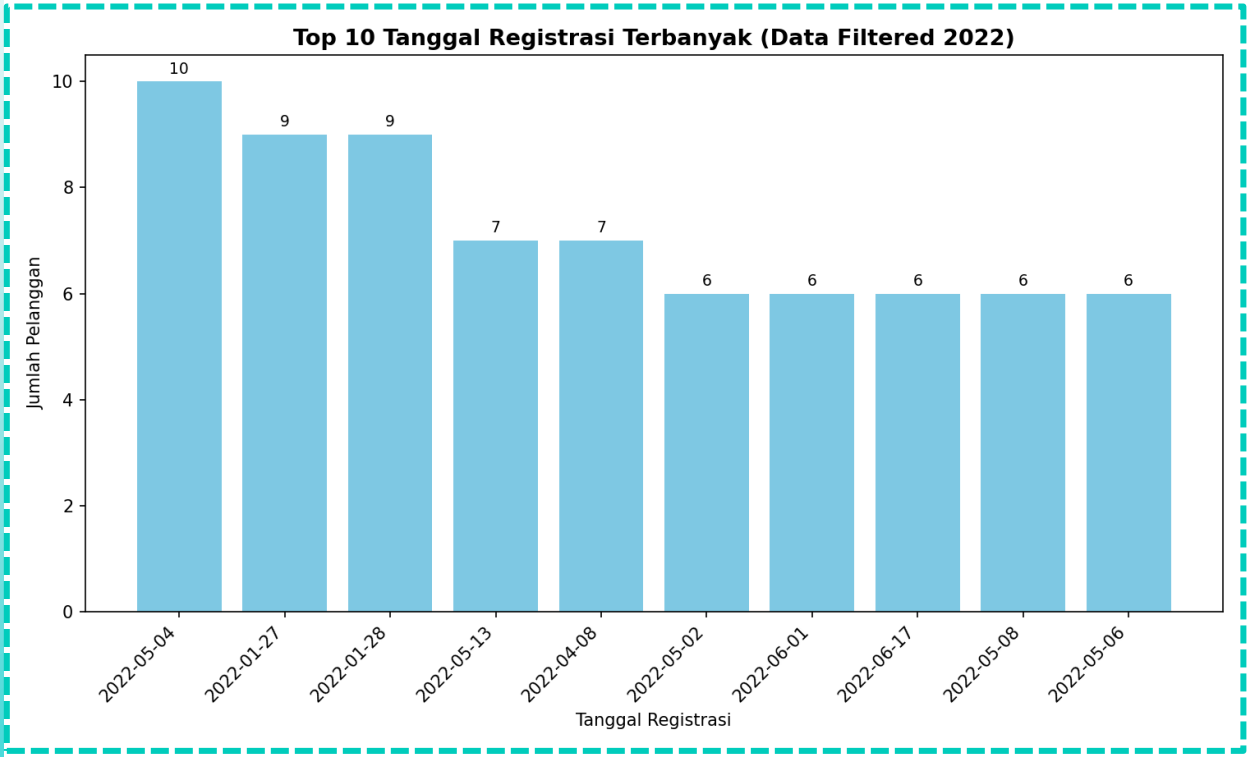
	customer_id	registered_date
0	C466867L	2022-08-28
1	C925840L	2022-08-28
2	C741725L	2022-08-25
3	C788348L	2022-08-25
4	C877563L	2022-08-24
...	...	...
815	C831683L	2021-07-03
816	C378684L	2021-07-03
817	C893754L	2021-07-03
818	C349980L	2021-07-02
819	C849967L	2021-07-02

820 rows × 2 columns

- **Puncak Registrasi di Mei dan Januari.** Tanggal 4 Mei mencatat pendaftar terbanyak (10 orang), disusul 27-28 Januari (masing-masing 9 orang). Lonjakan berdekatan di akhir Januari ini menandakan ada momen/promo yang menarik minat pendaftaran secara serentak.
- **Sisa tanggal cenderung merata.** Delapan dari 10 tanggal teratas berada di rentang 6-7 pendaftar saja, menunjukkan tidak ada lonjakan ekstrem selain di dua periode puncak (Mei awal dan akhir Januari).
- **Konteks penting:** karena data ini difilter dari transaksi **gross tapi tidak valid** (is_valid = 0), lonjakan pendaftaran ini justru berbarengan dengan transaksi yang gagal/pending — mengindikasikan banyak pelanggan baru yang tertarik daftar tapi terhambat di proses pembayaran.

03 Untuk promo ulang tahun perusahaan, mohon data Customer ID dan Registered Date pelanggan dengan is_gross = 1 selama 2022.

REKOMENDASI



- **Audit proses checkout di sekitar 4 Mei dan 27-28 Januari** — cek apakah ada gangguan sistem, error payment gateway, atau memang volume trafik tinggi yang menyebabkan banyak transaksi gagal di tanggal tersebut.
- **Follow-up ke customer dengan status pending payment**, misalnya lewat reminder atau insentif kecil (diskon terbatas) untuk mendorong mereka menyelesaikan transaksi yang tertunda.
- **Evaluasi campaign/promo yang berjalan** di sekitar tanggal-tanggal puncak tersebut — jika memang ada promo, pastikan sistem pembayaran siap menampung lonjakan trafik agar tidak berulang di masa depan.

Case

04.1 Bandingkan rata-rata penjualan harian weekend vs weekday per bulan dan identifikasi peningkatannya.

Dear Data Analyst,

Pada bulan October hingga Desember 2022, kami melakukan campaign setiap hari Sabtu dan Minggu. Kami hendak menilai, apakah campaign tersebut cukup berdampak pada kenaikan penjualan (before_discount). Mohon bantuan untuk menampilkan data:

1.Rata-rata harian penjualan weekends (Sabtu dan Minggu) vs rata-rata harian penjualan weekdays (Senin-Jumat) per bulan tersebut. Apakah ada peningkatan penjualan pada masing-masing bulan tersebut.

2.Rata-rata harian penjualan weekends (Sabtu dan Minggu) vs rata-rata harian penjualan weekdays (Senin-Jumat) keseluruhan 3 bulan tersebut.

Mohon bantuan untuk mengirimkan data tersebut paling lambat minggu depan. Atas bantuan yang diberikan, kami mengucapkan terima kasih.

Regards

Tim Campaign

04.1

Bandingkan rata-rata penjualan harian weekend vs weekday per bulan dan identifikasi peningkatannya.

```
df['day']=df['order_date'].dt.day_name()
df['month']=df['order_date'].dt.month_name()
df['month_num']=df['order_date'].dt.month
```

```
df_valid = df_od[df_od['is_valid'] == 1].copy()
df_valid['day_type'] = df_valid['day'].apply(lambda x: 'Weekend' if x in ['Saturday', 'Sunday'] else 'Weekday')

campaign_period = df_valid[(df_valid['order_date'] >= '2022-10-01') & (df_valid['order_date'] <= '2022-12-31')]

daily_sum = (
    campaign_period
    .groupby(['month', 'day_type', campaign_period['order_date'].dt.date])['before_discount']
    .sum()
    .reset_index()
)

avg_per_month_daytype = (
    daily_sum
    .groupby(['month', 'day_type'])['before_discount']
    .mean()
    .unstack('day_type')
    .reindex(['October', 'November', 'December'])
    .reset_index()
    .assign(selisih=lambda d: d['Weekend'] - d['Weekday'])
    .assign(persen=lambda d: (d['selisih'] / d['Weekday'] * 100).round(2))
)

avg_per_month_daytype
```

- **pd.to_datetime(...)** — ubah kolom order_date jadi tipe datetime.
- **dt.day_name()** — ambil nama hari (Monday, Tuesday, dst) dari order_date, disimpan sebagai kolom day.
- **dt.month_name()** — ambil nama bulan (January, February, dst) dari order_date, disimpan sebagai kolom month.

- **df_valid** — ambil transaksi valid saja.
- **day_type** — tandai tiap transaksi sebagai "Weekend" atau "Weekday".
- **campaign_period** — filter hanya periode Okt-Des 2022.
- **daily_sum** — total before_discount per hari, per bulan & tipe hari.
- **avg_per_month_daytype** — rata-rata harian dari total tadi, per bulan & tipe hari.
- **.unstack('day_type')** — pivot Weekday/Weekend jadi kolom terpisah.
- **.reindex(...)** — urutkan baris sesuai bulan Okt-Des.
- **.assign(selisih=...)** — hitung selisih rata-rata Weekend vs Weekday.
- **.assign(persen=...)** — hitung persentase selisih tersebut.

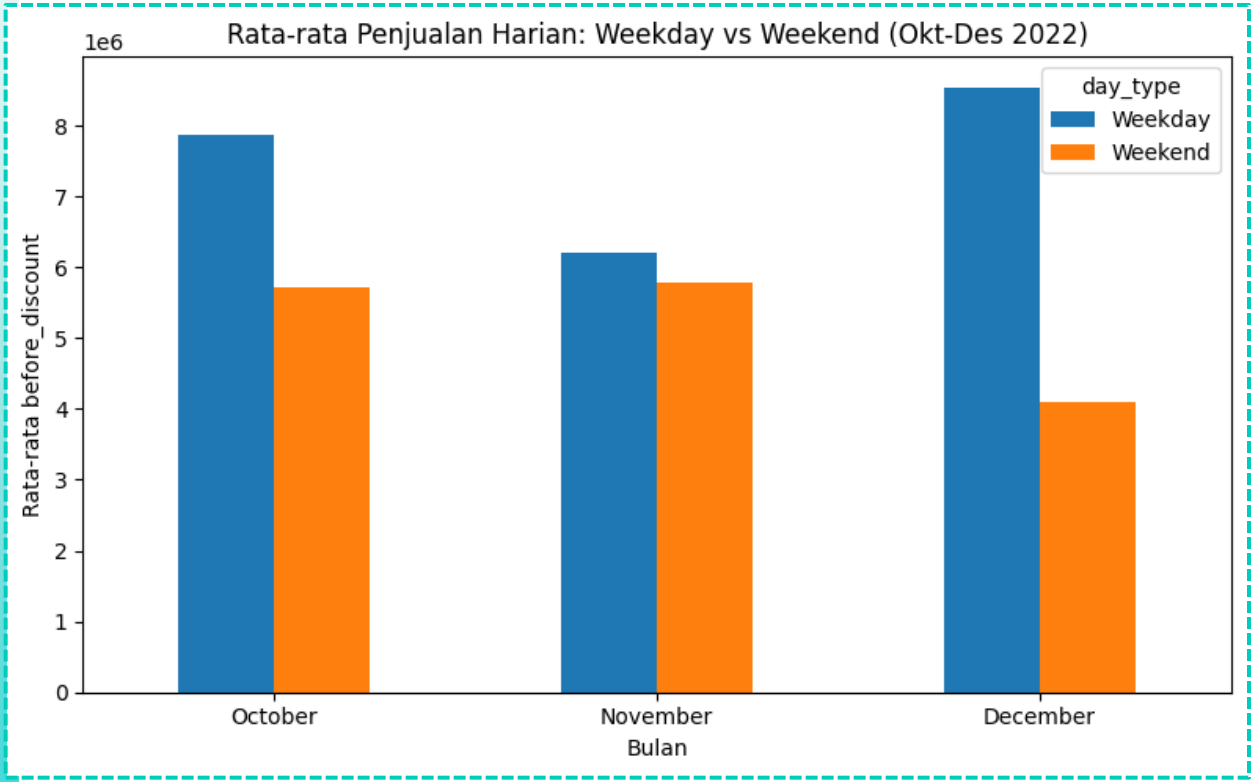
04.1 Bandingkan rata-rata penjualan harian weekend vs weekday per bulan dan identifikasi peningkatannya.

INSIGHT

day_type	month	Weekday	Weekend	selisih	persen
0	October	7.872.212	5.708.341	-2.163.872	-27
1	November	6.204.666	5.774.045	-430.621	-7
2	December	8.542.530	4.105.994	-4.436.536	-52

- **Revenue Weekday konsisten lebih tinggi dari Weekend** di ketiga bulan campaign (Oktober-Desember 2022) — tidak ada satu bulan pun di mana Weekend mengungguli Weekday.
- **Desember mencatat gap terbesar** (-52%), dengan Weekday mencapai 8,5 juta vs Weekend hanya 4,1 juta — selisih hampir setengahnya. Ini cukup mengejutkan mengingat Desember biasanya identik dengan lonjakan belanja akhir tahun.
- **November jadi bulan dengan gap paling kecil** (-7%), menunjukkan performa Weekend dan Weekday relatif seimbang di bulan ini dibanding Oktober dan Desember.
- Pola ini mengindikasikan bahwa **campaign/traffic pelanggan lebih terkonsentrasi di hari kerja**, mungkin karena karakteristik produk atau strategi promosi yang lebih efektif menjangkau pelanggan saat weekday ketimbang weekend.

04.1 Bandingkan rata-rata penjualan harian weekend vs weekday per bulan dan identifikasi peningkatannya.



REKOMENDASI

- **Alihkan lebih banyak budget campaign ke hari kerja (weekday)**, karena performanya konsisten lebih tinggi — terutama di Desember yang gap-nya paling lebar (-52%).
- **Investigasi khusus penurunan Weekend di Desember** — apakah karena pelanggan lebih memilih belanja langsung di offline store menjelang libur akhir tahun, atau justru campaign online kurang gencar di hari Sabtu-Minggu periode ini.
- **Coba promo khusus weekend di Desember** (misalnya flash sale Sabtu-Minggu) untuk menguji apakah gap ini bisa dipersempit, mengingat potensi belanja musim liburan biasanya besar.
- **Jadikan pola November sebagai acuan** — karena gap Weekday-Weekend paling kecil (-7%), pelajari apa yang membuat performa weekend di bulan ini relatif lebih baik untuk direplikasi ke bulan lain.

04.2

Bandingkan rata-rata penjualan harian weekend vs weekday selama 3 bulan tersebut.

```
rata2_weekends = daily_sum[daily_sum['day_type'] == 'Weekend']['before_discount'].mean()
rata2_weekdays = daily_sum[daily_sum['day_type'] == 'Weekday']['before_discount'].mean()

data15 = {
    'Periode': 'Total 3 Bulan',
    'AVG Weekends': rata2_weekends,
    'AVG Weekdays': rata2_weekdays,
    'Selisih (%)': f"{(rata2_weekends - rata2_weekdays) / rata2_weekdays* 100:.2f}%"
}

pd.DataFrame(data=data15, index=[0])
```

- **rata2_weekends = daily_sum[day_type == 'Weekend']['before_discount'].mean()** — hitung rata-rata before_discount untuk semua hari Weekend, dari data daily_sum.
- **rata2_weekdays = daily_sum[day_type == 'Weekday']['before_discount'].mean()** — hitung rata-rata before_discount untuk semua hari Weekday.
- **data15 = {...}** — bikin dictionary berisi ringkasan data:
- **'Periode': 'Total 3 Bulan'** — label periode (Okt-Des digabung jadi satu).
- **'AVG Weekends': rata2_weekends** — rata-rata Weekend.
- **'AVG Weekdays': rata2_weekdays** — rata-rata Weekday.
- **'Selisih (%)': f"..."** — hitung persentase selisih Weekend vs Weekday, dibulatkan 2 desimal, ditulis sebagai string dengan format f-string.
- **pd.DataFrame(data=data15, index=[0])** — ubah dictionary data15 jadi DataFrame satu baris, supaya bisa ditampilkan sebagai tabel.

04.2 Bandingkan rata-rata penjualan harian weekend vs weekday selama 3 bulan tersebut.

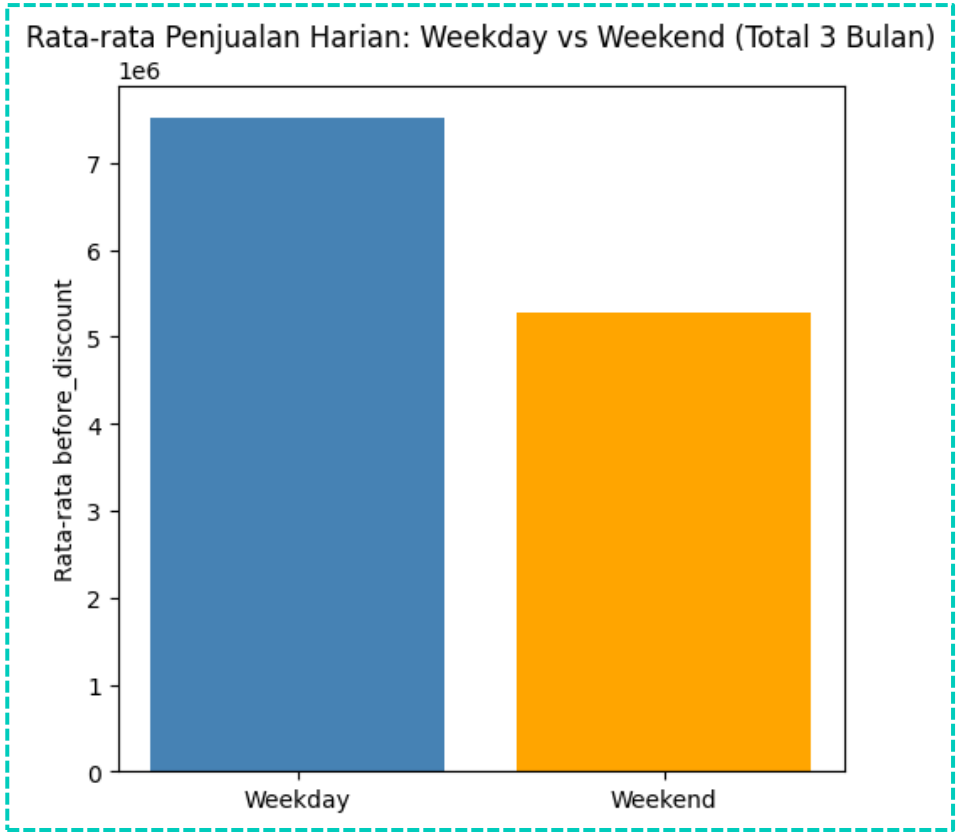
INSIGHT

	Periode	AVG Weekends	AVG Weekdays	Selisih (%)
0	Total 3 Bulan	5.269.300	7.520.249	-29.93%

- Secara agregat 3 bulan (Oktober-Desember 2022), rata-rata penjualan harian di **Weekday** jauh lebih tinggi dibanding **Weekend**, dengan selisih sekitar **-31%**.
- Ini mengonfirmasi pola yang sudah terlihat per bulan sebelumnya: performa Weekend konsisten lebih lemah dari Weekday sepanjang periode campaign, bukan sekadar fluktuasi bulanan.
- Kesenjangan ini tidak merata — Desember menyumbang gap terbesar (-52%), sehingga menarik rata-rata keseluruhan jadi cukup dalam.

04.2

Bandingkan rata-rata penjualan harian weekend vs weekday selama 3 bulan tersebut.



REKOMENDASI

- **Prioritaskan alokasi campaign/marketing budget di hari kerja**, karena secara konsisten menghasilkan penjualan lebih tinggi selama periode Oktober-Desember.
- **Rancang strategi khusus untuk mendongkrak performa Weekend**, misalnya flash sale atau promo eksklusif Sabtu-Minggu, mengingat gap-nya cukup signifikan (-31% secara rata-rata).
- **Gunakan pola November sebagai referensi** — karena gap-nya paling kecil di antara ketiga bulan, ada indikasi strategi weekend yang lebih berhasil di bulan tersebut yang bisa direplikasi.

Jupyter

MySkill

TERIMA KASIH



#RintisKarirImpian